

Relatório de Acompanhamento de PFC 2

Aluno: Luiz Miguel De Jesus Santiago

Professor Orientador: Prof. Dr. Emerson Alves da Silva

Curso de Engenharia de Controle e Automação

Universidade Federal de Minas Gerais (UFMG)

Resumo

Este documento apresenta o segundo relatório de acompanhamento do Projeto Final de Curso (PFC), intitulado "Sistema de Identificação Automática de Plantas de Primeira e Segunda Ordem". O relatório descreve as atividades realizadas no segundo ciclo do projeto, centradas em dois eixos complementares: o estudo do segundo curso da Deep Learning Specialization, "Improving Deep Neural Networks: Hyperparameter Tuning, Regularization and Optimization" (Coursera/DeepLearning.AI), e a expansão significativa do dataset de curvas de resposta ao degrau de 450 para 1.200 imagens. Diferentemente do ciclo anterior, nenhum exercício prático do curso foi adaptado ao contexto do PFC; em vez disso, o foco recaiu sobre a aplicação dos novos conhecimentos teóricos, com ênfase no ajuste de hiperparâmetros e no diagnóstico de modelos, para refinar os classificadores já desenvolvidos. Os ganhos de precisão obtidos foram marginais (inferiores a 2%), evidenciando que o modelo havia atingido um platô com a arquitetura densa atual, o que motiva a transição planejada para redes neurais convolucionais (CNNs) na próxima etapa.

1 Introdução

O segundo ciclo de atividades do PFC foi concebido como uma etapa de consolidação e refinamento, com duplo objetivo: ampliar o repertório teórico em técnicas avançadas de treinamento de redes neurais e investigar em que medida o aumento da base de dados e a melhor calibração de hiperparâmetros seriam capazes de elevar a acurácia dos classificadores desenvolvidos no ciclo anterior.

No ciclo anterior, os três exercícios da primeira especialização foram adaptados ao domínio de classificação de sistemas dinâmicos, e o melhor modelo obtido (uma rede neural profunda densa) atingiu acurácia de 93% sobre um dataset de 450 imagens (250 de primeira ordem e 200 de segunda ordem), com separação treino/teste definida pelas primeiras 45 amostras. Embora satisfatório para um estágio inicial, tal resultado deixava margem para investigar o impacto de técnicas de regularização, otimizadores mais eficientes e maior volume de dados.

Neste segundo ciclo, portanto, o foco deslocou-se da construção de novos exercícios adaptados para a utilização do ferramental teórico do segundo curso como instrumento de diagnóstico e otimização dos modelos já existentes. Paralelamente, o dataset foi expandido e balanceado, passando a conter 1.200 imagens igualmente distribuídas entre as duas classes. Os resultados obtidos, contudo, revelaram ganhos modestos, indicando limitações inerentes à arquitetura densa adotada e sinalizando a necessidade de incorporar arquiteturas convolucionais nas próximas fases.

2 Atividades Desempenhadas

As atividades deste segundo período do projeto concentraram-se em duas frentes: a formação teórica por meio do segundo curso da Deep Learning Specialization e a expansão e reanálise do dataset, com aplicação prática dos conceitos estudados. A seguir são descritas as atividades realizadas.

2.1 Estudo do curso "Improving Deep Neural Networks: Hyperparameter Tuning, Regularization and Optimization"

O segundo curso da Deep Learning Specialization aprofunda o entendimento sobre os mecanismos que governam o desempenho de redes neurais profundas, abordando técnicas práticas que permitem diagnosticar e corrigir sistematicamente problemas comuns de treinamento. Os conteúdos estão organizados em três semanas temáticas, descritas a seguir.

Semana 1: Aspectos Práticos do Aprendizado Profundo. Foram estudadas as boas práticas para a divisão dos dados em conjuntos de treino, desenvolvimento (dev) e teste, com ênfase na necessidade de que os conjuntos de dev e teste compartilhem a mesma distribuição estatística. O curso abordou a análise do balanço entre viés (bias) e variância como ferramenta diagnóstica central, bem como técnicas de regularização (L2 e dropout) para mitigar o sobreajuste. Foram estudados ainda os conceitos de vanishing e exploding gradientes e estratégias de inicialização de pesos (He e Xavier) para estabilizar o treinamento. O módulo introduziu também a verificação numérica do gradiente (gradient checking) como ferramenta de depuração da implementação do algoritmo de retropropagação.

Semana 2: Algoritmos de Otimização. Esta semana abordou alternativas ao gradiente descendente em lote (batch gradient descent), com destaque para o mini-batch gradient descent, que acelera a convergência ao processar subconjuntos dos dados a cada iteração. Foram estudados os algoritmos de momentum, RMSprop e Adam (este último uma combinação dos dois anteriores), além das médias exponencialmente ponderadas que fundamentam esses métodos. O conceito de correção de viés (bias correction) nas estimativas de momentum também foi introduzido.

Semana 3: Ajuste de Hiperparâmetros, Batch Normalization e Frameworks. A última semana tratou de estratégias sistemáticas para o ajuste de hiperparâmetros, incluindo a busca aleatória em escala logarítmica como alternativa à busca em grade (grid search). Foi estudada a Batch Normalization como técnica de normalização das ativações intermediárias, que acelera o treinamento e confere maior robustez à escolha da taxa de aprendizado. O módulo encerrou com uma introdução ao TensorFlow como framework de referência para a implementação de redes neurais em nível de produção.

Embora o curso incluía exercícios de programação em notebooks Jupyter (sobre regularização, métodos de otimização e implementação em TensorFlow), neste ciclo optou-se por não adaptá-los ao domínio do PFC, priorizando a utilização dos conceitos teóricos diretamente sobre os modelos e o dataset do projeto.

2.2 Expansão do Dataset

Uma das limitações identificadas ao final do ciclo anterior era o volume relativamente reduzido de dados: 450 imagens com distribuição assimétrica entre as classes (250 de primeira ordem e 200 de segunda ordem). Para investigar o impacto do aumento de dados sobre a acurácia dos classificadores, o dataset foi sistematicamente ampliado e balanceado.

O novo dataset conta com 1.200 imagens, sendo 600 de sistemas de primeira ordem e 600 de sistemas de segunda ordem, mantendo o equilíbrio entre as classes. A geração das novas amostras seguiu o mesmo protocolo do ciclo anterior: curvas de resposta ao degrau simuladas numericamente para diferentes combinações de parâmetros (constante de tempo τ e ganho estático K para sistemas de primeira ordem; frequência natural ω_n , coeficiente de amortecimento ζ e ganho estático K para sistemas de segunda ordem), discretizadas e salvas como imagens de 64×64 pixels. A semente aleatória e o protocolo de normalização dos pixels para o intervalo de $-0,5$ a $0,5$ foram mantidos, preservando a comparabilidade com os resultados anteriores.

Com o dataset expandido, a divisão treino/teste foi ajustada proporcionalmente, mantendo a razão aproximada de 90/10 entre treino e teste, de forma a preservar a representatividade estatística de ambos os conjuntos e evitar distorções na avaliação dos modelos.

2.3 Aplicação dos Conhecimentos Teóricos e Resultados Obtidos

Com base no ferramental teórico adquirido no curso, foram realizadas análises diagnósticas sobre os modelos treinados no ciclo anterior, utilizando as curvas de perda e acurácia em treino e desenvolvimento para identificar o regime predominante (viés vs. variância). Essas análises orientaram os ajustes realizados neste ciclo.

Os principais pontos de otimização identificados e explorados foram:

- Taxa de aprendizado: a análise das curvas de convergência revelou que a taxa de aprendizado de 0,005, adotada nos exercícios 2 e 3 do ciclo anterior, poderia ser reduzida para valores entre 0,001 e 0,003, resultando em convergência mais estável e menor oscilação da função de perda nas iterações finais.
- Número de iterações: verificou-se que, para o dataset expandido, o número de iterações de 5.000 adotado anteriormente mostrava sinais de convergência precoce para algumas configurações, sendo elevado para até 8.000 iterações em experimentos selecionados.
- Análise de viés e variância: os modelos avaliados com o novo dataset apresentaram perfil predominante de alto viés (underfitting) para configurações mais simples de arquitetura, e variância elevada (overfitting) para configurações com maior número de neurônios. Este diagnóstico corrobora a hipótese de que a arquitetura densa atingiu um platô de desempenho para o problema em questão.

Apesar dos ajustes realizados, os ganhos de precisão obtidos foram marginais. O modelo que havia atingido 93% de acurácia no ciclo anterior alcançou, com o dataset expandido e os novos ajustes de hiperparâmetros, uma acurácia máxima inferior a 95%, representando um ganho inferior a 2 pontos percentuais. Este resultado, embora positivo, evidencia que a fronteira de decisão imposta pela arquitetura densa está próxima de seu limite para o conjunto de dados atual.

Um fator adicional que contribui para este teto de desempenho é a homogeneidade visual do dataset: as imagens variam principalmente no perfil da curva de resposta ao degrau, com ausência de sobressinal para sistemas de primeira ordem versus presença e intensidade do sobressinal para sistemas de segunda ordem, mas compartilham escalas, backgrounds e estrutura de ruído semelhantes. Essa baixa variabilidade intraclasse limita os benefícios do aumento de dados e reforça a necessidade de diversificação do dataset nas próximas etapas, tanto em termos de condições de geração quanto de formato de representação das curvas.

3 Próximas Atividades

Os resultados deste segundo ciclo, em particular o platô de desempenho identificado nas arquiteturas densas, orientam as prioridades das próximas etapas do projeto. As atividades previstas são:

1. Estudo e implementação de Redes Neurais Convolucionais (CNNs): a realização do quarto curso da Deep Learning Specialization, "Convolutional Neural Networks", constituirá a principal atividade de capacitação do próximo ciclo. As CNNs são naturalmente adequadas ao problema de classificação de curvas de resposta representadas como imagens, uma vez que exploram a estrutura espacial dos dados por

meio de filtros convolucionais aprendidos, esperando-se ganhos significativos de acurácia em relação às redes densas.

2. Expansão e diversificação do dataset: o dataset atual, embora balanceado em volume, apresenta baixa variabilidade intraclasse. As próximas iterações de geração de dados incluirão variações nas condições de plotagem (escalas, estilos de linha, presença de ruído aditivo nas curvas), diferentes janelas temporais de observação e diferentes amplitudes de degrau, com o objetivo de tornar os modelos mais robustos a condições reais de medição.
3. Projeto e avaliação de arquiteturas convolucionais para o problema de identificação: com base nos conceitos do curso de CNNs, serão projetadas e comparadas diferentes arquiteturas convolucionais, incluindo variações de profundidade, tamanho de kernel e estratégias de pooling, aplicadas à classificação de ordem de sistemas dinâmicos.
4. Validação paramétrica incremental: em paralelo ao desenvolvimento das CNNs, serão iniciados experimentos de estimação dos parâmetros dos sistemas (constante de tempo, coeficiente de amortecimento, frequência natural), avançando do problema de classificação de ordem para o problema de identificação propriamente dito, alinhado ao objetivo central do PFC.

4 Conclusão

O segundo ciclo do PFC consolidou dois avanços importantes: a aquisição de um repertório técnico mais amplo em treinamento e diagnóstico de redes neurais profundas, por meio do segundo curso da Deep Learning Specialization, e a estruturação de um dataset significativamente maior e balanceado, com 1.200 imagens de curvas de resposta ao degrau.

Contudo, os resultados experimentais revelaram que os ganhos de acurácia obtidos com o aumento de dados e com o refinamento de hiperparâmetros foram modestos, inferiores a 2 pontos percentuais, sugerindo que a arquitetura densa atingiu um platô de desempenho para o problema em questão. Este diagnóstico, longe de representar um insucesso, é informativo: indica que a fronteira de decisão linear por partes oferecida por redes densas é insuficiente para extrair plenamente as características discriminativas das curvas de resposta representadas como imagens.

A análise de viés e variância conduzida com as ferramentas do segundo curso foi particularmente valiosa para fundamentar essa conclusão de forma sistemática, em contraste com a abordagem mais exploratória do ciclo anterior. Esses diagnósticos orientarão diretamente as decisões de projeto nas próximas fases, em especial a transição para arquiteturas convolucionais e a diversificação do dataset, que se apresentam como os próximos passos naturais para superar o teto de desempenho identificado e avançar em direção ao objetivo central do projeto.