

Relatório de Acompanhamento de PFC 1

Aluno: Luiz Miguel De Jesus Santiago

Professor Orientador: Prof. Dr. Emerson Alves da Silva

Curso de Engenharia de Controle e Automação

Universidade Federal de Minas Gerais (UFMG)

Resumo

Este documento apresenta o relatório de acompanhamento do Projeto Final de Curso (PFC), intitulado "Sistema de Identificação Automática de Plantas de Primeira e Segunda Ordem". O relatório detalha o progresso inicial das atividades, centradas na capacitação técnica em Deep Learning como fundamento para o desenvolvimento do sistema proposto. Em especial, são descritas as atividades realizadas no primeiro ciclo formativo, que consistiu na conclusão do primeiro curso "Neural Networks and Deep Learning" da Deep Learning Specialization (Coursera/DeepLearning.AI), com a particularidade de que todos os exercícios práticos foram adaptados para o contexto de classificação de sistemas de primeira e segunda ordem.

1 Introdução

A etapa inicial deste Projeto Final de Curso foi dedicada à consolidação dos fundamentos teóricos e computacionais necessários para o desenvolvimento do sistema de identificação automática de plantas dinâmicas. O projeto, enquadrado na área de Controle e Otimização de Processos, tem como objetivo central o desenvolvimento de um sistema capaz de identificar por meio de visão computacional e inteligência artificial, os modelos de plantas de primeira e segunda ordem a partir de dados visuais, como curvas de resposta ao degrau.

A abordagem adotada neste projeto une dois campos do conhecimento: a teoria de identificação de sistemas, consolidada nas disciplinas do curso de Engenharia de Controle e Automação, e o aprendizado profundo (deep learning), área que provê as ferramentas computacionais para o reconhecimento de padrões em dados experimentais. Para viabilizar essa integração, foi identificada a necessidade de uma capacitação estruturada e aprofundada em redes neurais artificiais.

Dessa forma, o primeiro ciclo do PFC foi dedicado à realização do curso "Neural Networks and Deep Learning", primeiro módulo da Deep Learning Specialization oferecida pela DeepLearning.AI na plataforma Coursera, ministrada pelo Prof. Andrew Ng. A escolha deste percurso formativo foi motivada pela sua reconhecida qualidade acadêmica e pelo alinhamento direto com os requisitos computacionais do projeto, em particular, a necessidade de compreender arquiteturas de redes neurais densas, inicialização de parâmetros, funções de ativação e algoritmos de treinamento, que constituem a espinha dorsal dos modelos a serem desenvolvidos nas fases práticas.

2 Atividades Desempenhadas

Durante este primeiro período do projeto, os esforços foram concentrados na formação técnica em aprendizado profundo, com conclusão integral do primeiro curso da Deep Learning Specialization. A seguir são descritas as atividades realizadas.

2.1 Conclusão do curso "Neural Networks and Deep Learning"

O curso abrange os fundamentos teóricos e práticos das redes neurais artificiais, estruturados em quatro semanas de conteúdo progressivo. Os tópicos estudados incluíram: introdução ao aprendizado profundo e sua distinção frente ao aprendizado de máquina tradicional; regressão logística como base para a compreensão de neurônios artificiais; redes neurais rasas com uma camada oculta; redes neurais profundas (deep networks) com múltiplas camadas; e os fundamentos matemáticos do algoritmo de retropropagação (backpropagation) para o treinamento eficiente dessas arquiteturas.

Além das aulas teóricas, o curso disponibiliza exercícios de programação em Python (notebooks Jupyter) que consolidam os conceitos por meio da implementação prática. Todos esses exercícios foram concluídos com êxito ao longo deste primeiro período.

2.2 Adaptação dos exercícios ao contexto do PFC

A principal diferença em relação ao percurso padrão do curso foi a decisão metodológica de adaptar os três exercícios de programação propostos para o domínio específico do PFC: a classificação de sistemas dinâmicos de primeira e segunda ordem. Em vez de utilizar os *datasets* originais fornecidos (como o de reconhecimento de imagens de gatos), optou-se pela construção de conjuntos de dados próprios. Estas bases foram compostas por curvas de resposta ao degrau simuladas com diferentes combinações de parâmetros (constante de tempo, ganho estático, coeficiente de amortecimento e frequência natural, conforme aplicável). Vale ressaltar que o *dataset* desenvolvido contou com 450 imagens, sendo 200 de sistemas de segunda ordem e 250 de primeira ordem.

Cada exercício foi recontextualizado da seguinte forma:

1. Exercício 1 — Regressão Logística como Rede Neural: implementação de um classificador binário capaz de distinguir sistemas de primeira ordem de sistemas de segunda ordem, a partir das curvas de resposta ao degrau representadas como vetores de amostras temporais.
2. Exercício 2 — Rede Neural Rasa (1 camada oculta): extensão do classificador para uma arquitetura de rede neural com uma camada oculta, avaliando o ganho de desempenho na separação das classes (primeira vs. segunda ordem) em função do número de neurônios ocultos.
3. Exercício 3 — Rede Neural Profunda (Várias camadas): implementação de uma rede neural profunda com múltiplas camadas ocultas para a mesma tarefa de classificação,

explorando o efeito da profundidade da rede na acurácia de identificação da ordem do sistema.

Essa abordagem permitiu não apenas a assimilação dos conceitos de deep learning, mas também uma primeira validação experimental da viabilidade da proposta central do PFC: a de que redes neurais artificiais são capazes de aprender a distinguir a ordem de um sistema dinâmico a partir de sua resposta temporal. Os resultados obtidos nos três exercícios foram satisfatórios, indicando boa separabilidade das classes nas arquiteturas testadas.

Ao finalizar os exercícios, obteve-se uma acurácia máxima de 93% no conjunto de dados desenvolvido. Além disso, à medida que a rede neural se tornou mais complexa com a adição de camadas ocultas, encontrar a melhor configuração de hiperparâmetros passou a ser uma tarefa mais difícil. Mais especificamente, a transição do segundo para o terceiro exercício tornou o alcance de 90% de precisão um desafio.

Para todos os modelos avaliados, os dados passaram por um fluxo de processamento padronizado, no qual as imagens foram redimensionadas para 64x64 pixels, resultando em 12.288 atributos de entrada. Os dados foram separados usando as primeiras 45 amostras para treinamento e o restante para teste, sob uma semente aleatória fixa de valor 42. Uma etapa crucial foi a normalização dos pixels para o intervalo de -0,5 a 0,5, essencial para evitar a inativação prematura dos neurônios nas redes mais profundas.

No primeiro exercício, correspondente a uma regressão logística de camada única com ativação sigmoide e inicialização de pesos zerada, o treinamento foi configurado para 2.000 iterações com uma taxa de aprendizado elevada de 0,5. No segundo exercício, a introdução de uma camada oculta com ativação ReLU demandou mudanças drásticas para garantir a estabilidade do gradiente descendente em lote: a taxa de aprendizado foi reduzida para 0,005 e adotaram-se as inicializações de *He* e *Xavier* para as matrizes de pesos. O modelo base dessa fase utilizou 8 neurônios ocultos e 5.000 iterações, embora testes paralelos tenham explorado de 1 a 150 neurônios durante 2.000 iterações. Por fim, no terceiro exercício, a arquitetura foi estabilizada utilizando uma única camada oculta com tamanho variando entre 8 e 16 neurônios, mantendo a taxa de aprendizado em 0,005 e o ciclo de treinamento em 5.000 iterações.

3 Próximas Atividades

Com base na capacitação teórica consolidada neste primeiro ciclo, as próximas etapas seguirão o cronograma estabelecido na proposta, avançando para os módulos subsequentes da Deep Learning Specialization e, em seguida, para a fase de projeto e implementação do sistema. As atividades previstas são:

4. Realização dos módulos seguintes da Deep Learning Specialization: os cursos "Improving Deep Neural Networks" e "Convolutional Neural Networks" serão

cursados para consolidar técnicas de regularização, otimização (Adam, RMSprop), ajuste de hiperparâmetros e estratégias de diagnóstico de modelos, essenciais para o refinamento do sistema de identificação.

5. Definição da estratégia de identificação: com base no embasamento teórico acumulado, será definida a arquitetura final do sistema, incluindo o tipo de rede neural a ser empregada (densa, convolucional ou recorrente), o formato da entrada (curva de resposta ao degrau discretizada) e a representação da saída (parâmetros do modelo identificado).
6. Validação das abordagens versus identificações reais: os modelos desenvolvidos serão confrontados com sistemas cujos parâmetros são previamente conhecidos, utilizando métricas de erro paramétrico (erro percentual em ganho, constante de tempo e amortecimento) como critério de validação.
7. Configuração do ambiente de desenvolvimento: estruturação do repositório de código, do pipeline de geração de dados sintéticos e do ambiente de treinamento, utilizando Python (NumPy, SciPy, PyTorch) e as workstations do Laboratório de Sistemas Inteligentes (LSI/DELT/UFGM).

4 Conclusão

Considerando que o projeto encontra-se em seu estágio inicial, o progresso obtido neste primeiro período é avaliado como satisfatório. A conclusão integral do curso "Neural Networks and Deep Learning", com a diferenciação metodológica de ter adaptado todos os exercícios ao contexto de classificação de sistemas de primeira e segunda ordem, representa um avanço duplo: a aquisição do ferramental teórico de deep learning e uma primeira evidência experimental da viabilidade da abordagem proposta para o PFC.

A imersão prática nas implementações dos exercícios permitiu identificar aspectos relevantes do problema, como a importância da normalização das curvas de entrada e a sensibilidade dos classificadores a variações paramétricas, que orientarão as decisões de projeto nas fases seguintes. Dessa forma, o cronograma permanece alinhado com as expectativas estabelecidas na proposta, e as próximas etapas, de caráter mais aplicado, serão executadas sobre uma base técnica sólida.