

Relatório de Acompanhamento de PFC 3

Aluno: Luiz Miguel De Jesus Santiago

Professor Orientador: Prof. Dr. Emerson Alves da Silva

Curso de Engenharia de Controle e Automação

Universidade Federal de Minas Gerais (UFMG)

Resumo

Este documento apresenta o terceiro relatório de acompanhamento do Projeto Final de Curso (PFC) intitulado "Sistema de Identificação Automática de Plantas de Primeira e Segunda Ordem". Neste ciclo, as atividades concentraram-se em dois eixos principais: (i) a expansão e parametrização completa do script de geração sintética do dataset de imagens de resposta ao degrau, e (ii) o estudo teórico e prático de Redes Neurais Convolucionais (CNNs) por meio do quarto curso da Deep Learning Specialization (Coursera/DeepLearning.AI), "Convolutional Neural Networks". Com base nesses avanços, discute-se também a arquitetura candidata para a tarefa ampliada do PFC, que passa a contemplar não apenas a classificação da ordem do sistema, mas também a estimação dos parâmetros de sua função de transferência a partir da imagem da curva de resposta ao degrau.

1 Introdução

O terceiro ciclo de desenvolvimento do PFC marcou uma evolução significativa em duas frentes complementares. Na frente de dados, o script Python responsável pela geração sintética das curvas de resposta ao degrau foi reformulado para permitir a parametrização completamente aleatória dos sistemas gerados, variando livremente ganho estático, constante de tempo, coeficiente de amortecimento, frequência natural não-amortecida, resolução das imagens e cor das curvas. Essa revisão eleva substancialmente a diversidade e a robustez do dataset, condição indispensável para o treinamento de modelos generalizáveis.

Na frente metodológica, foi realizado o estudo do quarto curso da Deep Learning Specialization: "Convolutional Neural Networks". Este curso fornece o embasamento teórico e prático para a adoção de CNNs como arquitetura principal do sistema de identificação. As CNNs apresentam vantagens naturais para o problema em questão: ao processar a curva de resposta ao degrau como imagem, filtros convolucionais aprendem automaticamente características morfológicas relevantes, como tempo de subida, sobressinal, tempo de acomodação e valor de regime permanente, sem a necessidade de extração manual de atributos.

Adicionalmente, com o amadurecimento da compreensão do problema, o escopo da tarefa de saída foi ampliado: o sistema deverá não apenas classificar a ordem da planta (primeira ou segunda ordem), mas também estimar os parâmetros que definem sua função de

transferência, tornando o problema uma tarefa híbrida de classificação e regressão, demandando escolhas arquiteturais mais cuidadosas.

2 Atividades Desempenhadas

2.1 Expansão e parametrização do script de geração do dataset

A primeira versão do script de geração de dados impunha restrições fixas sobre os parâmetros dos sistemas simulados, resultando em um dataset homogêneo com baixa variabilidade intraclasse. Para tornar o conjunto de dados adequado ao treinamento de um modelo robusto, a segunda versão do script foi completamente reparametrizada com os seguintes graus de liberdade:

- Sistemas de primeira ordem: ganho estático K e constante de tempo τ sorteados aleatoriamente dentro de faixas fisicamente significativas para processos industriais típicos.
- Sistemas de segunda ordem: ganho estático K , frequência natural não-amortecida ω_n e coeficiente de amortecimento ζ sorteados aleatoriamente, abrangendo os regimes subamortecido ($0 < \zeta < 1$), criticamente amortecido ($\zeta = 1$) e superamortecido ($\zeta > 1$).
- Resolução das imagens: variada aleatoriamente para simular diferentes condições de aquisição e testar a invariância do modelo a mudanças de escala.
- Cor das curvas e estilo visual do gráfico: randomizados para impedir que o modelo aprenda artefatos espúrios de cor em vez das características dinâmicas da curva.
- Ruído aditivo sobre as curvas: introduzido opcionalmente para simular sinais experimentais ruidosos e aumentar a robustez do modelo a perturbações.

Essa refatoração do gerador de dados é uma contribuição central para a viabilidade do projeto, pois garante que o modelo treinado aprenda representações verdadeiramente invariantes às condições de apresentação da curva e não correlações espúrias decorrentes de um dataset pouco diverso.

2.2 Definição do tamanho do dataset

Uma questão central neste ciclo foi a determinação de um tamanho adequado para o dataset. A análise considerou a natureza da tarefa (classificação binária combinada com regressão paramétrica multivariada), a dimensionalidade da entrada (imagens), e as práticas consolidadas na literatura de aprendizado de máquina aplicado a problemas de identificação de sistemas.

Um dataset de 50.000 imagens foi, inicialmente, considerado distribuídas da seguinte forma:

- 25.000 imagens de sistemas de primeira ordem, com pares de parâmetros (K , τ) uniformemente distribuídos nas faixas definidas.

- 25.000 imagens de sistemas de segunda ordem, com ternas (K , ω_n , ζ) distribuídas de forma a garantir cobertura adequada dos três regimes de amortecimento (subamortecido, crítico e superamortecido), com maior densidade amostral na região subamortecida por ser a mais frequente em aplicações práticas de controle.

Essa escala é suportada pela geração sintética automatizada, o custo computacional de produzir 50.000 imagens com o script desenvolvido é baixo e pode ser executado em poucas horas. Adicionalmente, técnicas de data augmentation (rotação leve, zoom e inversão horizontal, quando aplicáveis e semanticamente válidas para curvas de resposta ao degrau) poderão ser exploradas para multiplicar artificialmente a diversidade do conjunto. Para as fases de desenvolvimento, o dataset será dividido nas proporções 70% treino, 15% validação e 15% teste.

2.3 Estudo do curso "Convolutional Neural Networks" (Curso 4 da Deep Learning Specialization)

O curso foi concluído integralmente e abrange quatro semanas de conteúdo estruturado, cobrindo desde os fundamentos matemáticos das convoluções até arquiteturas modernas e aplicações especializadas. Os principais tópicos estudados foram:

1. Semana 1 — Fundamentos das CNNs: operação de convolução (padding, stride, filtros), camadas de pooling (max e average pooling), e implementação manual em NumPy das operações de forward e backward propagation de uma camada convolucional. O exercício de programação "Convolution Model Step by Step" consolidou matematicamente o funcionamento dos filtros e sua capacidade de detectar padrões locais.
2. Semana 2 — Arquiteturas profundas e estudos de caso: análise das arquiteturas clássicas (LeNet-5, AlexNet, VGG-16) e modernas (ResNets e Inception Networks). O exercício de implementação de Residual Networks (ResNets) com blocos de identidade e convolucionais em TensorFlow/Keras demonstrou como conexões residuais (skip connections) mitigam o problema do gradiente desvanecente em redes muito profundas e permitem o treinamento de arquiteturas com dezenas de camadas.
3. Semana 3 — Detecção de objetos: algoritmos de sliding window, Intersection over Union (IoU), Non-Max Suppression (NMS) e o algoritmo YOLO (You Only Look Once). Embora a detecção de objetos não seja o objetivo central do PFC, os conceitos de localização espacial e predição de múltiplos valores por imagem são diretamente relevantes para a tarefa de regressão paramétrica.
4. Semana 4 — Aplicações especiais: reconhecimento facial (one-shot learning, redes siamesas e funções de perda triplet) e transferência de estilo neural. O conceito de transfer learning, explorado ao longo do curso, é particularmente relevante para o PFC, pois permite aproveitar representações aprendidas em grandes datasets de visão computacional como ponto de partida para o domínio específico das curvas de resposta ao degrau.

2.4 Definição da arquitetura candidata para o PFC

Com base no estudo das CNNs e na compreensão aprofundada do problema de identificação de sistemas, foi esboçada uma arquitetura candidata para o modelo principal do PFC. O desafio agora é consideravelmente mais rico que a classificação binária do ciclo anterior: o sistema deverá, a partir de uma única imagem de resposta ao degrau, (i) determinar a ordem da planta e (ii) retornar os parâmetros da função de transferência correspondente.

Para sistemas de primeira ordem, a função de transferência tem a forma $G(s) = K / (\tau s + 1)$, com dois parâmetros a estimar (K e τ). Para sistemas de segunda ordem, a forma canônica é $G(s) = K\omega_n^2 / (s^2 + 2\zeta\omega_n s + \omega_n^2)$, com três parâmetros (K , ζ , ω_n). A heterogeneidade dos espaços de saída em função da classe identificada impõe que a arquitetura seja concebida como uma rede de saída dupla (multi-head), estruturada da seguinte forma:

- **Backbone convolucional compartilhado:** responsável pela extração de características visuais da curva de resposta ao degrau. A arquitetura ResNet-18 ou uma CNN customizada de profundidade moderada são as candidatas iniciais, privilegiando a capacidade de aprender características de forma (tempo de subida, sobressinal, tempo de acomodação) invariantes à escala e à cor.
- **Cabeça de classificação (Classification Head):** camada densa conectada ao backbone, com saída softmax de duas classes (primeira ou segunda ordem). A métrica de validação será a acurácia de classificação.
- **Cabeças de regressão (Regression Heads):** duas saídas densas paralelas, uma para os parâmetros de primeira ordem (K , τ) e outra para os de segunda ordem (K , ζ , ω_n). Durante a inferência, somente a cabeça correspondente à classe predita pelo classification head será utilizada. A função de perda combinada será uma soma ponderada da cross-entropy (classificação) e do erro quadrático médio normalizado (regressão paramétrica).

Embora uma abordagem alternativa baseada na predição direta dos coeficientes polinomiais de uma função de transferência genérica pudesse parecer estruturalmente mais simples ao unificar o problema em uma única camada de regressão, essa via revela-se consideravelmente mais complexa e instável na prática. Ao regredir coeficientes polinomiais brutos em vez dos parâmetros canônicos, o modelo perde a correlação geométrica direta com a morfologia da curva visual (como a relação estrita entre sobressinal e amortecimento). Além disso, a predição implícita de um sistema de primeira ordem dentro de uma estrutura genérica de segunda ordem exigiria que a rede neural, que opera com otimização em espaços contínuos, predissesse um zero absoluto para o coeficiente de maior grau do denominador, o que é altamente improvável e resultaria na geração de pólos de alta frequência parasitas. Nessa formulação, desvios numéricos mínimos na estimação dos coeficientes deslocariam os polos de forma não linear, podendo facilmente comprometer a estabilidade do sistema predito.

Dessa forma, a arquitetura multi-task proposta permite o treinamento conjunto das tarefas de classificação e regressão de maneira robusta, aproveitando a representação compartilhada aprendida pelo backbone para ambas as saídas, sem comprometer a estabilidade matemática inerente aos sistemas de controle. A validação do modelo será realizada tanto por métricas de classificação quanto por métricas de regressão (erro percentual médio nos parâmetros estimados em relação aos valores reais simulados).

3 Próximas Atividades

Com o dataset expandido e a arquitetura candidata definida, as próximas etapas concentrar-se-ão na implementação e validação experimental do modelo. As atividades planejadas são:

5. Geração do dataset definitivo: execução do script parametrizado para produção das 50.000 imagens.
6. Implementação do backbone e das cabeças de saída: codificação da arquitetura multi-head, com definição da função de perda combinada (classificação + regressão) e dos otimizadores (Adam com learning rate scheduling).
7. Treinamento e ajuste de hiperparâmetros: execução dos primeiros ciclos de treinamento, monitorando as curvas de perda e acurácia em treino e validação para diagnóstico de overfitting ou underfitting.
8. Validação contra sistemas reais: confronto dos parâmetros estimados pelo modelo com os valores reais de sistemas cujos parâmetros são conhecidos previamente, calculando o erro paramétrico percentual como métrica de desempenho final.
9. Redação da monografia (PFC I): início da redação dos capítulos de introdução, revisão bibliográfica e metodologia, conforme cronograma da disciplina PFC I.

4 Conclusão

O terceiro ciclo do PFC consolidou dois avanços essenciais para a maturidade do projeto. A refatoração do gerador de dados, com parametrização completamente aleatória de todos os aspectos visuais e dinâmicos das curvas, elevou substancialmente a qualidade e a diversidade do dataset sintético. Paralelamente, o estudo aprofundado das CNNs, cobrindo desde as operações convolucionais fundamentais até arquiteturas avançadas como ResNets e Inception Networks, forneceu o embasamento necessário para a concepção de uma arquitetura multi-task adequada à complexidade do problema.

A decisão de expandir o escopo do sistema para além da classificação da ordem, incorporando a estimação dos parâmetros da função de transferência, representa uma evolução natural e tecnicamente justificada do objetivo original do PFC. Essa ampliação demanda uma arquitetura mais sofisticada e um dataset maior, desafios para os quais as ferramentas e o conhecimento adquiridos neste ciclo oferecem resposta direta. O cronograma

permanece alinhado com os objetivos da proposta, e o projeto avança de forma sólida em direção à fase de implementação e validação experimental.